Prodi Matematika
Fakultas Sains dan Teknologi
UIN Syarif Hidayatullah Jakarta

STUDI KOMPARATIF MODEL SARIMAX, LIGHTGBM, DAN HYBRID SARIMAX-LIGHTGBM DALAM PREDIKSI JUMLAH PENGGUNA HARIAN BUS RAPID TRANSIT TRANSJAKARTA

Nama : Syafiqah Marsya Kholiyadi
NIM : 11220940000056

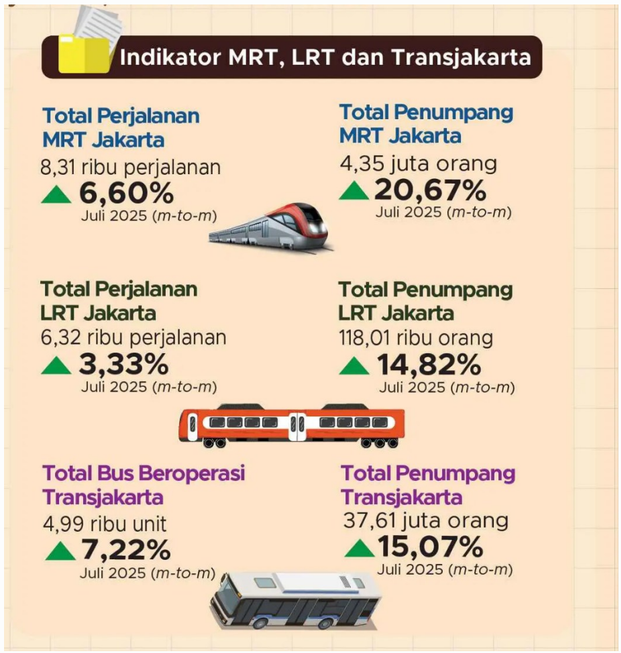
Dosen Pembimbing I : Ibu Dhea Urfina Zulkifli, M.SI.
Dosen Pembimbing II : Ibu Yannne Irene, M.SI.

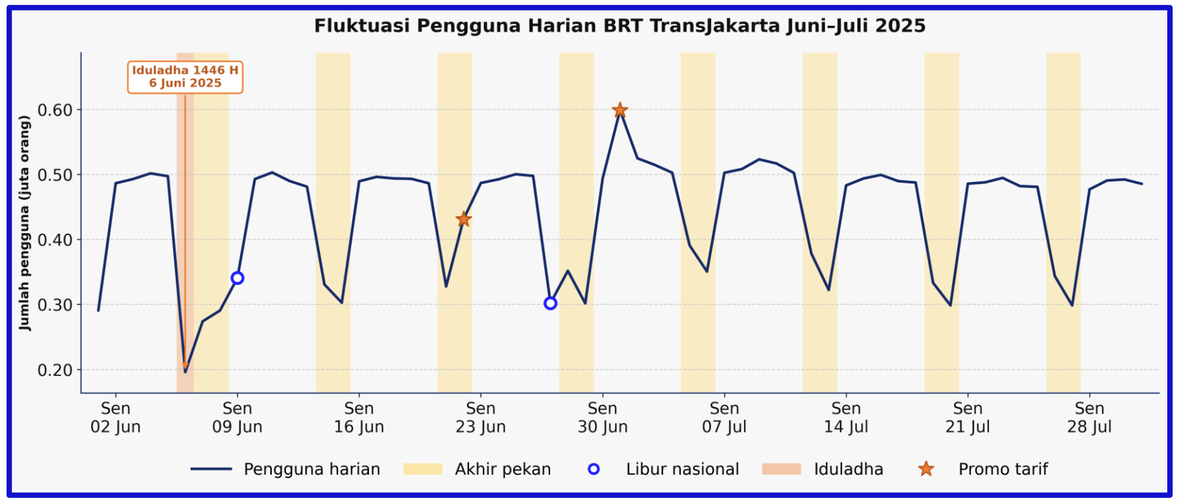
Dosen Penguji I : Bapak Muhammad Manaqib, M.Sc.
Dosen Penguji II : Ibu Anggun Praptaningsih, S.Pd., M.Mat.

LATAR BELAKANG

Prodi Matematika
Fakultas Sains dan Teknologi
UIN Syarif Hidayatullah Jakarta

Sumber: laporan BPS Provinsi DKI Jakarta





Musiman

Faktor eksternal

Pola permintaan yang berubah dari waktu ke waktu memerlukan perencanaan operasional layanan yang tepat.

Alokasi armada TransJakarta

Penjadwalan oprasional

Penyesuaian kapasitas

Dibutuhkan prediksi jumlah pengguna harian BRT transjakarta yang akurat

LATAR BELAKANG

Prodi Matematika
Fakultas Sains dan Teknologi
UIN Syarif Hidayatullah Jakarta

Dibutuhkan model yang sesuai dengan karakteristik data untuk memperoleh prediksi yang akurat.

SARIMAX	Pola linear, musiman mingguan, dan variabel exogen	Model Statistik Linear
LIGHTGBM	Hubungan non-linear melalui fitur lag, rolling statistic, cyclic encoding, dan variabel eksogen	Model Machine Learning Non-Linear
SARIMAX-LIGHTGBM	SARIMAX memodelkan pola linear, LightGBM memodelkan pola non linear pada residual	Model Hybrid berbasis Residual

PENELITIAN TERDAHULU

Prodi Matematika
Fakultas Sains dan Teknologi
UIN Syarif Hidayatullah Jakarta

Abdelghany et. al	Fazli et. al	M.Patel et. al.	Chen et. al	Patel et. al
• Metode: SARIMA, SARIMAX, dan VAR • Data: Penumpang rute penerbangan • Variabel exogen: kapasitas kursi dan tarif	• Metode: SARIMAX dan XGBOOST • Data: LRT Jakarta • Variabel: akhir pekan, libur nasional, promo tarif, libur panjang, hampir libur panjang	• Metode: LightGBM, XGBOOST, CatBoost • Data: passenger flow station-pair TMT • Variabel : timeslot, weekday, dan holiday	• Metode : hybrid SARIMAX-LightGBM (prediksi SARIMAX sebagai fitur LightGBM) • Data: Pengguaan listrik pendingin ruangan • Variabel: Suhu, curah hujan, dan kelembapan.	• Metode : TBATS, SARIMA, LightGBM, XGBOOST, dan Hybrid TBATS-LightGBM • Data: hourly passenger flow TMT • Variabel: akhir pekan dan covid
SARIMAX dengan variabel exogen menghasilkan prediksi yang lebih akurat	SARIMAX sebagai model terbaik	LightGBM sebagai model terbaik dengan waktu komputasi yang efisien	Hybrid menghasilkan kinerja prediksi yang baik, tetapi tidak dibandingkan dengan model standalone	Hybrid sebagai model terbaik dan meningkatkan akurasi model standalone.

Penelitian Ini : Membandingkan model SARIMAX, LightGBM dan Hybrid.

GAP → **Belum terdapat penelitian yang membandingkan ketiga model pada data BRT TransJakarta.**

TUJUAN PENELITIAN

1. Mengetahui kinerja model SARIMAX, LightGBM, dan hybrid SARIMAX–LightGBM dalam peramalan jumlah pengguna harian BRT TransJakarta.

2. Menentukan model yang memberikan akurasi terbaik dalam memprediksi jumlah pengguna BRT TransJakarta berdasarkan metrik evaluasi MAPE, MAE, san RMSE.

MODEL SARIMAX

pengembangan model SARIMA$(p,d,q)(P,D,Q)_s$ yang mempertimbangkan pengaruh faktor-faktor eksternal terhadap variabel target

$$Y_t = \beta_0 + \beta_1 X_{1,t} + \beta_2 X_{2,t} + \cdots + \beta_k X_{k,t} + \frac{\theta_q(B)\Theta_Q(B^S)}{\varphi_p(B)\phi_P(B^S)(1-B)^d(1-B^S)^D}\varepsilon_t$$

Komponen Regresi

Komponen eror yang mengikuti proses SARIMA

- Y_t : data runtun waktu pada waktu pengamatan ke-t,
- $\theta_q(B)$: faktor MA non musiman,
- $\theta_Q(B^S)$: faktor seasonal MA,
- $\varphi_p(B)$: faktor AR non seasonal,
- $\phi_P(B^S)$: komponen Seasonal AR,
- $(1-B)^d$: order *differencing* non seasonal,
- $(1-B^S)^D$: order *differencing* musiman,
- ε_t : residual model SARIMAX.

MODEL LIGHTGBM

Fitur Input → Prediksi Awal → Hitung Error → Pohon Mempelajari Eror → Perbarui Prediksi → Ulangi → Prediksi Ahir

Rumus Pembaruan Prediksi

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(x_i)$$

Prediksi baru = prediksi sebelumnya + nilai koreksi dari pohon baru

Fungsi Objektif

$$\mathcal{L} = \sum_{i=1}^{n} l\left(y_i, \hat{y}_i + f_t(x_i)\right) + \sum_{k=1}^{K} \Omega(f_k)$$

Loss mengukur error, regulasi mengontrol kompleksitas

y_i: nilai aktual pengamatan ke-i; $\hat{y}_i$: nilai prediksi pengamatan ke-i; $f_t(x_i)$: output pohon pada iterasi ke-t; l: fungsi loss; $\Omega(f_k)$: regularisasi pohon ke-k ; K: jumlah pohon

Histogram Based Algorithm

Nilai fitur dibagi ke dalam bin untuk mempercepat pencarian titik split

Exclusive Feature Bundling

Fitur yang jarang aktif bersamaan digabung untuk mengurangi jumlah fitur efektif

Leaf Wise Growth

Memilih leaf dengan penurunan loss terbesar. Kompleksitas dikendalikan oleh parameter seperti max_depth, num_leaves, dan min_data_in_leaf.

METRIK EVALUASI

MAE

$$\text{MAE} = \frac{\sum_{i=1}^{n} |y_i - \hat{y}_i|}{n}$$

MAPE

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^{n} \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\ \%$$

RMSE

$$\text{RMSE} = \sqrt{\frac{\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}{n}}$$

dengan:

n : jumlah data obeservasi

y_i : nilai observasi aktual pada pengamatan ke-i

$\hat{y}_i$: Nilai prediksi pada pengamatan ke-i

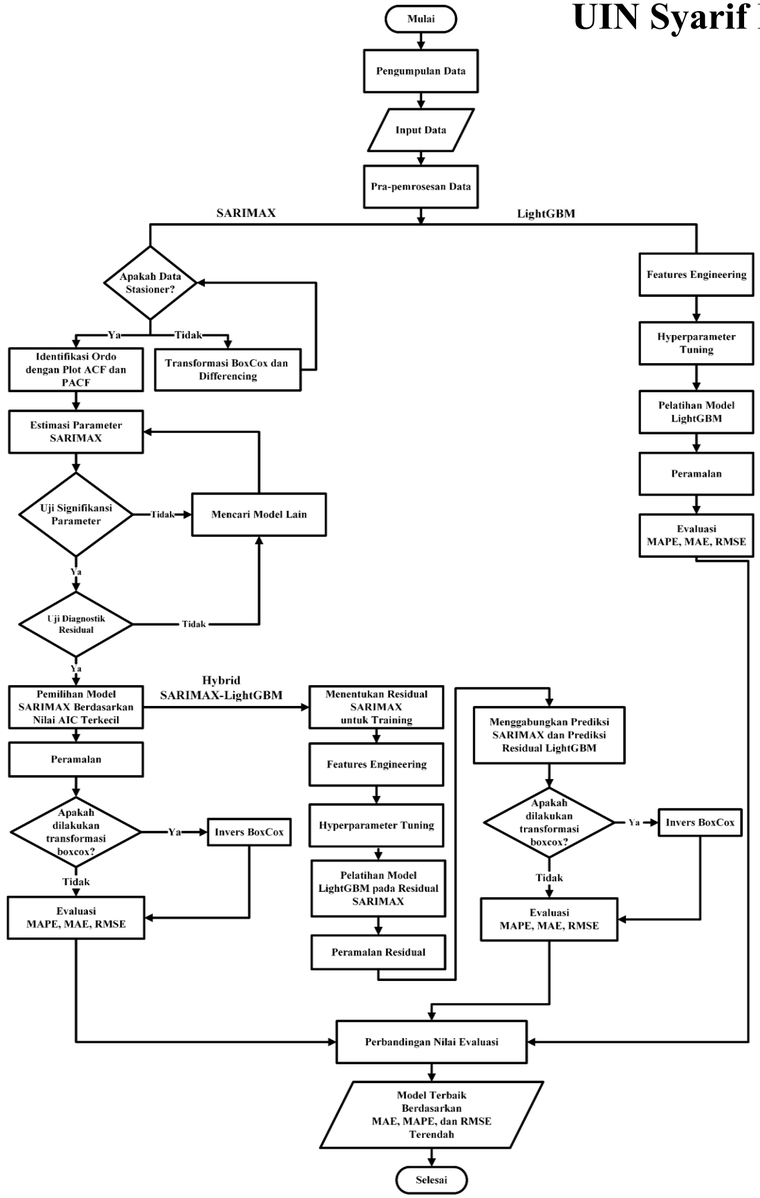
Persentase Nilai MAPE	Keterangan
Nilai MAPE $\leq 10\%$	Sangat Baik
$10\% <$ Nilai MAPE $\leq 20\%$	Baik
$20\% <$ Nilai MAPE $\leq 50\%$	Cukup
Nilai MAPE $> 50\%$	Kurang Baik

ALUR PENELITIAN

SARIMAX

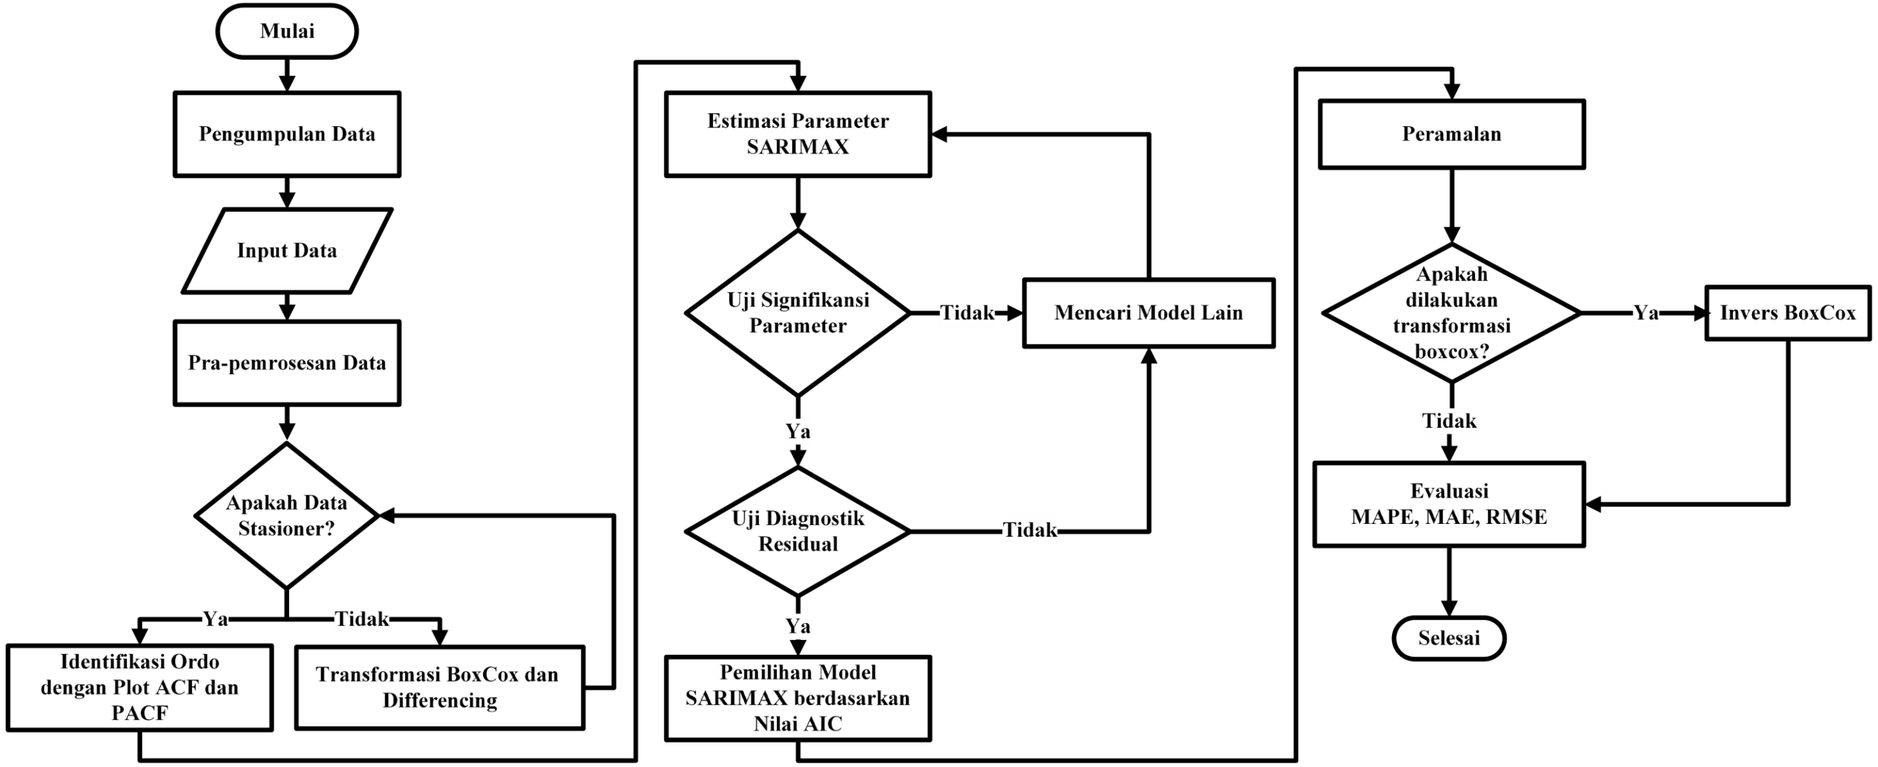
LIGHTGBM

SARIMAX-LIGHTGBM



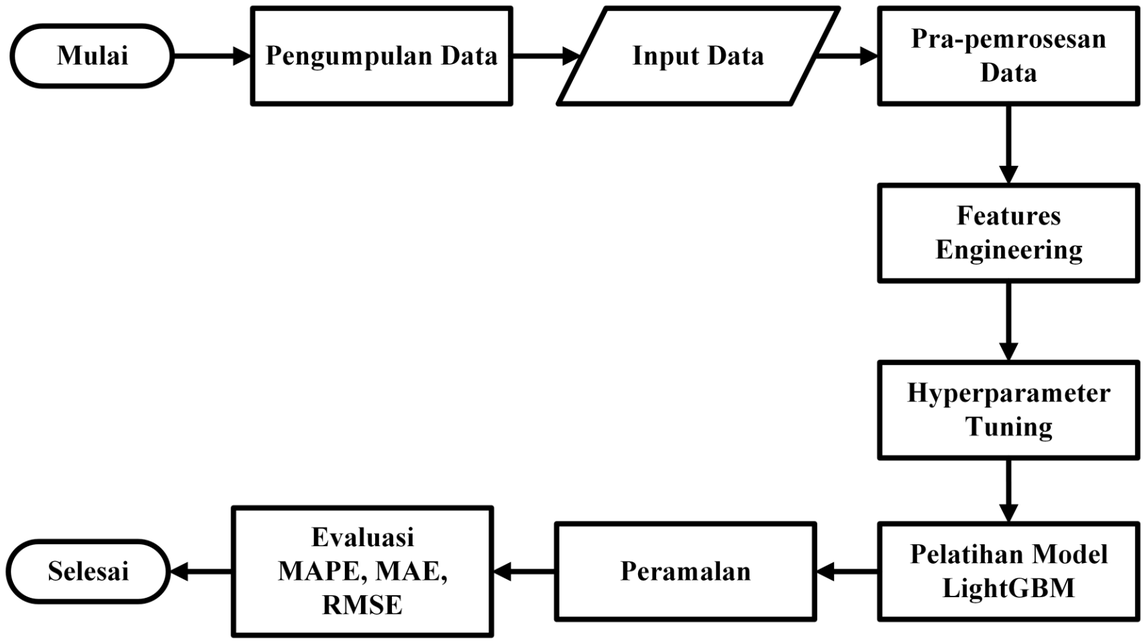
ALUR PENELITIAN

SARIMAX



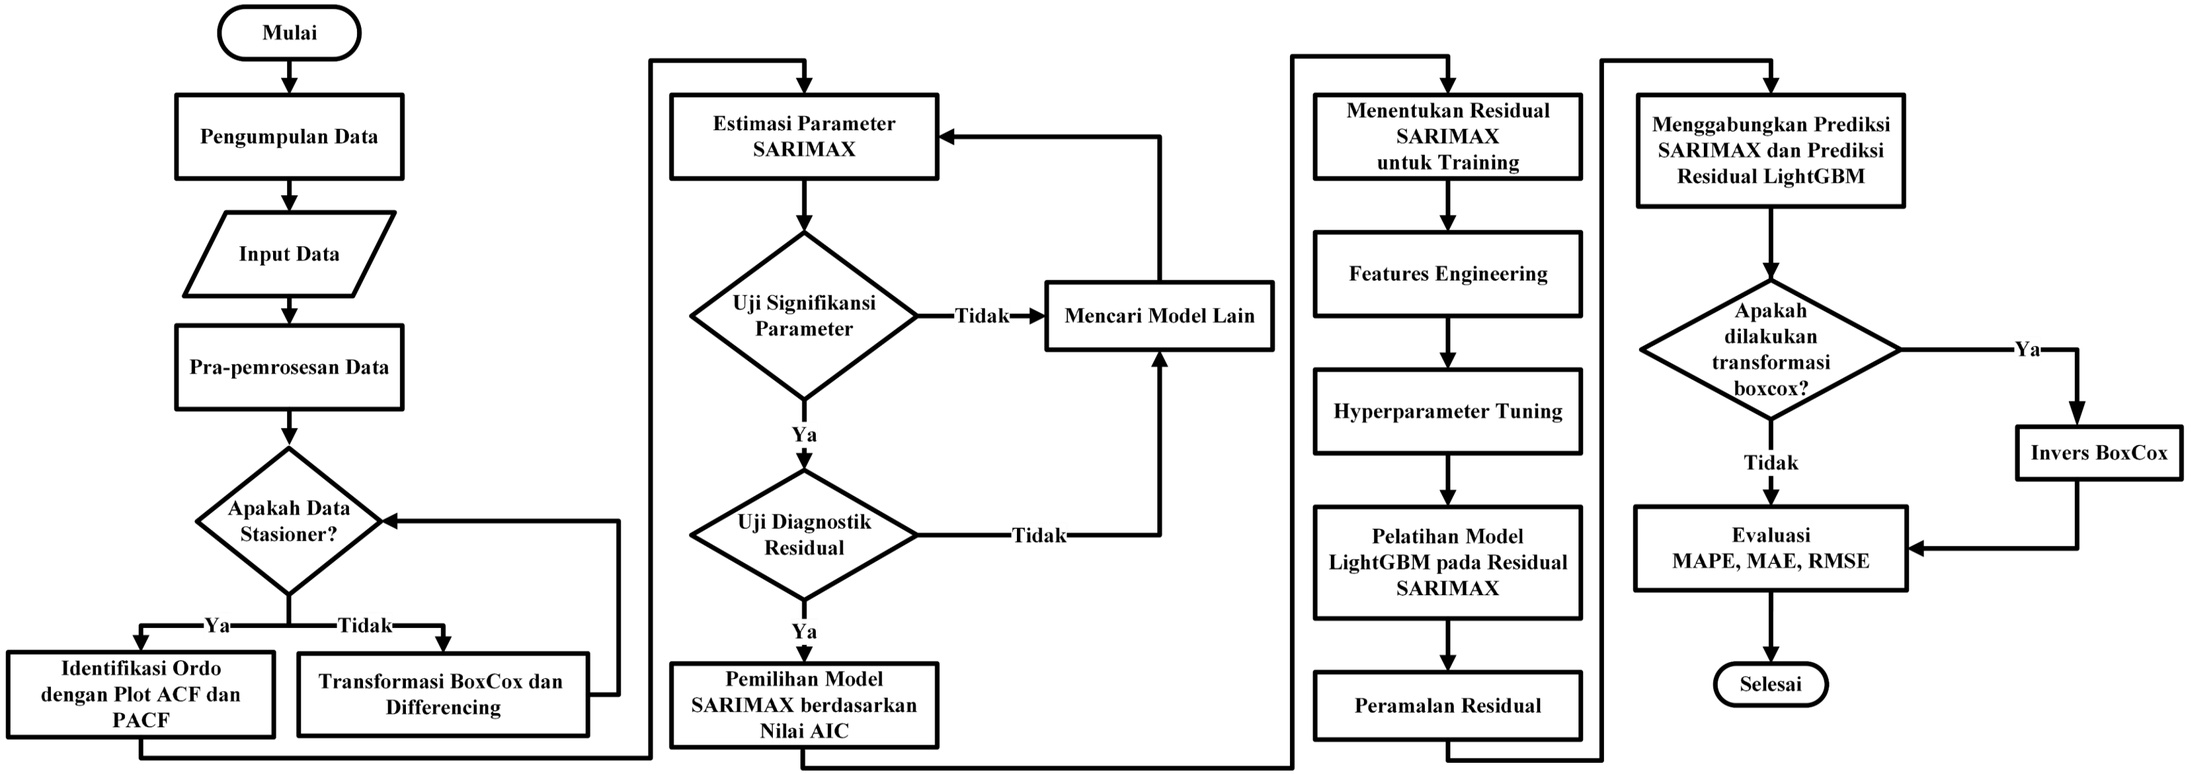
ALUR PENELITIAN

LIGHTGBM



ALUR PENELITIAN

SARIMAX-LIGHTGBM



DATA

Prodi Matematika
Fakultas Sains dan Teknologi
UIN Syarif Hidayatullah Jakarta

- Data Jumlah pengguna harian BRT TransJakarta.
- Sumber : PPID TransJakarta
- Link : ppid.transjakarta.co.id

1 Januari 2023 s.d. 31 Juli 2025

VARIABEL EKSOGEN

Dummy Kalender

Lebaran
Libur Nasional
Promo Tarif

Jumlah Data
943

Data Training
882

Data Testing
61

Missing Value : 0

Outlier berdasarkan IQR : 0

HASIL DAN PEMBAHASAN

SARIMAX

1 STASIONERITAS DATA

$\lambda = 0,7894795$

Tranformasi

BoxCox

Setelah tranformasi

$\lambda = 0,9730712$

Uji Stasioneritas Terhadap Mean			
Uji ADF		Uji KPSS	
Dickey Fuller	P-Value	KPSS Level	P-Value
-7,7338	0,01	5,7176	0,01
Data stasioner		Data tidak stasioner	

d=1

D=1

Setelah differencing

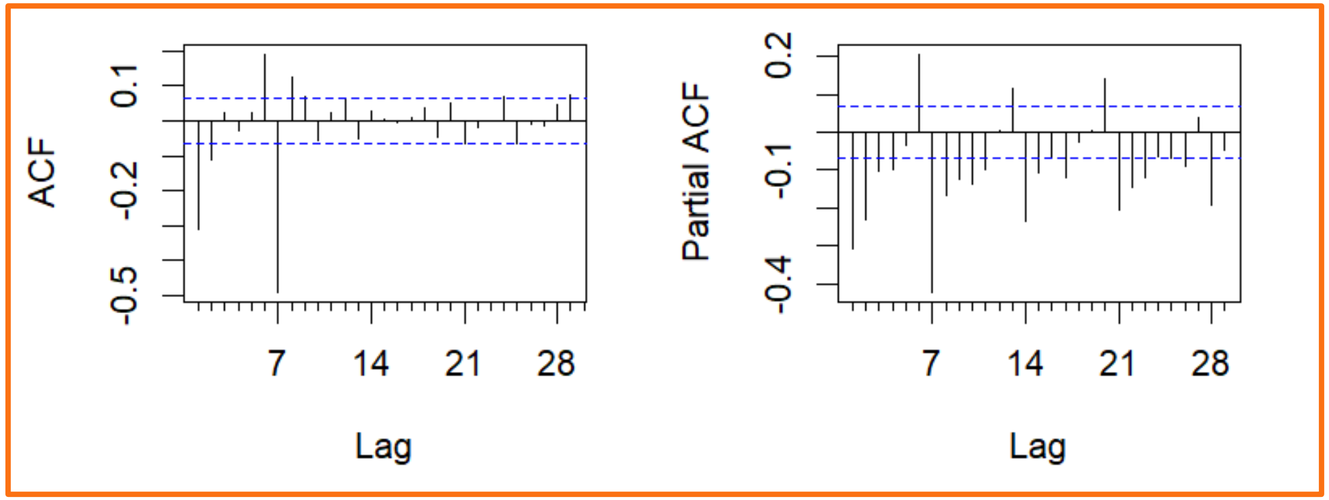
Uji Stasioneritas Terhadap Mean			
Uji ADF		Uji KPSS	
Dickey Fuller	P-Value	KPSS Level	P-Value
-16,966	0,01	0,0028516	0,1
Data stasioner		Data stasioner	

Data sudah stasioner dalam varians maupun mean

SARIMAX

2 IDENTIFIKASI MODEL SARIMAX $(p, d, q)(P, D, Q)_s$

Plot ACF dan PACF



Kandidat Orde

Parameter	Keterangan	Kandidat Orde
p	AR	0, 1, atau 2
d	Differencing	1
q	MA	0, 1, atau 2
P	SAR	0
D	Seasonal Differencing	1
Q	SMA	0 atau 1

SARIMAX

3 ESTIMASI MODEL SARIMAX $(p,d,q)(P,D,Q)_s$

No	Kandidat Model	Signifikansi Parameter
1	$SARIMAX(0,1,0)(0,1,0)_7$	Signifikan
2	$SARIMAX(0,1,1)(0,1,0)_7$	Signifikan
3	$SARIMAX(0,1,2)(0,1,0)_7$	Signifikan
4	$SARIMAX(0,1,0)(0,1,1)_7$	Signifikan
5	$SARIMAX(0,1,1)(0,1,1)_7$	Signifikan
6	$SARIMAX(0,1,2)(0,1,1)_7$	Signifikan
7	$SARIMAX(1,1,0)(0,1,0)_7$	Signifikan
8	$SARIMAX(1,1,1)(0,1,0)_7$	Signifikan
9	$SARIMAX(1,1,2)(0,1,0)_7$	Tidak signifikan
10	$SARIMAX(1,1,0)(0,1,1)_7$	Signifikan
11	$SARIMAX(1,1,1)(0,1,1)_7$	Signifikan
12	$SARIMAX(1,1,2)(0,1,1)_7$	Tidak signifikan
13	$SARIMAX(2,1,0)(0,1,0)_7$	Signifikan
14	$SARIMAX(2,1,1)(0,1,0)_7$	Tidak signifikan
15	$SARIMAX(2,1,2)(0,1,0)_7$	Signifikan
16	$SARIMAX(2,1,0)(0,1,1)_7$	Signifikan
17	$SARIMAX(2,1,1)(0,1,1)_7$	Tidak signifikan
18	$SARIMAX(2,1,2)(0,1,1)_7$	Tidak signifikan

Kandidat model dengan semua parameter dan variabel eksogen signifikan

No	Kandidat Model
1	$SARIMAX(0,1,0)(0,1,0)_7$
2	$SARIMAX(0,1,1)(0,1,0)_7$
3	$SARIMAX(0,1,2)(0,1,0)_7$
4	$SARIMAX(0,1,0)(0,1,1)_7$
5	$SARIMAX(0,1,1)(0,1,1)_7$
6	$SARIMAX(0,1,2)(0,1,1)_7$
7	$SARIMAX(1,1,0)(0,1,0)_7$
8	$SARIMAX(1,1,1)(0,1,0)_7$
9	$SARIMAX(1,1,0)(0,1,1)_7$
10	$SARIMAX(1,1,1)(0,1,1)_7$
11	$SARIMAX(2,1,0)(0,1,0)_7$
12	$SARIMAX(2,1,2)(0,1,0)_7$
13	$SARIMAX(2,1,0)(0,1,1)_7$

SARIMAX

4 UJI DIAGNOSTIK RESIDUAL

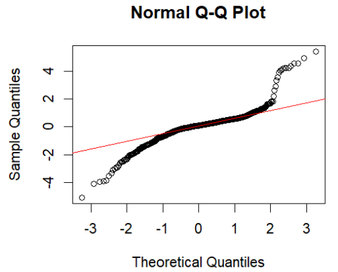
Uji L-JungBox

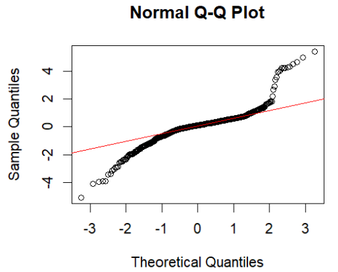
Kandidat Model	P-Values				Ket
	Lag-7	Lag-14	Lag-21	Lag-28	
$SARIMAX(0,1,0)(0,1,0)_7$	< 0.05	< 0.05	< 0.05	< 0.05	Tidak Layak
$SARIMAX(0,1,1)(0,1,0)_7$	< 0.05	< 0.05	< 0.05	< 0.05	Tidak Layak
$SARIMAX(0,1,2)(0,1,0)_7$	< 0.05	< 0.05	< 0.05	< 0.05	Tidak Layak
$SARIMAX(0,1,0)(0,1,1)_7$	< 0.05	< 0.05	< 0.05	< 0.05	Tidak Layak
$SARIMAX(0,1,1)(0,1,1)_7$	< 0.05	< 0.05	< 0.05	< 0.05	Tidak Layak
$SARIMAX(0,1,2)(0,1,1)_7$	**0,41**	**0,73**	**0,18**	**0,25**	**Layak**
$SARIMAX(1,1,0)(0,1,0)_7$	< 0.05	< 0.05	< 0.05	< 0.05	Tidak Layak
$SARIMAX(1,1,1)(0,1,0)_7$	< 0.05	< 0.05	< 0.05	< 0.05	Tidak Layak
$SARIMAX(1,1,0)(0,1,1)_7$	< 0.05	< 0.05	< 0.05	< 0.05	Tidak Layak
$SARIMAX(1,1,1)(0,1,1)_7$	**0,33**	**0,71**	**0,18**	**0,25**	**Layak**
$SARIMAX(2,1,0)(0,1,0)_7$	< 0.05	< 0.05	< 0.05	< 0.05	Tidak Layak
$SARIMAX(2,1,2)(0,1,0)_7$	< 0.05	< 0.05	< 0.05	< 0.05	Tidak Layak
$SARIMAX(2,1,0)(0,1,1)_7$	< 0.05	< 0.05	< 0.05	< 0.05	Tidak Layak

Model lolos uji Ljung-Box ➡ $SARIMAX(1,1,1)(0,1,1)_7$ & $SARIMAX(0,1,2)(0,1,1)_7$

Uji Normalitas

Kandidat Model	P-Values UJI Shapiro-Wilk
$SARIMAX(1,1,1)(0,1,1)_7$	$< 2.2\times e^{-16}$
$SARIMAX(0,1,2)(0,1,1)_7$	$< 2.2\times e^{-16}$





$SARIMAX(1,1,1)(0,1,1)_7$ | $SARIMAX(0,1,2)(0,1,1)_7$

Kedua model tidak berdistribusi normal

SARIMAX

5 MODEL SARIMAX$(p,d,q)(P,D,Q)_s$ TERBAIK

Nilai AIC Kandidat Model

Model	Nilai AIC
SARIMAX $(1,1,1)(0,1,1)_7$	15.648,22
SARIMAX $(0,1,2)(0,1,1)_7$	**15.648,13**

Nilai AIC terkecil ⟶ SARIMAX$(0,1,2)(0,1,1)_7$

Model SARIMAX Terbaik

Model	Parameter	Estimasi
SARIMAX $(0,1,2)(0,1,1)_7$	MA(1)	-0,7496
	MA(2)	-0,1370
	SMA(1)	-0,9748
	lebaran	-14.595,7166
	libur_nasional	-9.621,0531
	promo_tarif	4.362,7879

$$Z_t = -14.595,7166\ lebaran_t - 9.621,0531\ libur_nasional_t + 4.362,7879\ promo_tarif_t + \frac{(1-0,7496B-0,1370B^2)(1-0,9748B^7)}{(1-B)(1-B^7)}\varepsilon_t$$

dengan

$$Z_t = \frac{Y_t^{0,7894795}-1}{0,7894795}$$

Residual SARIMAX digunakan untuk pemodelan hybrid

FEATURE ENGINEERING

Prodi Matematika
Fakultas Sains dan Teknologi
UIN Syarif Hidayatullah Jakarta

1 LAG FEATURES

Kandidat lag: 1, 2, 3, 7, 14, dan 21

Tanggal	Jumlah pengguna harian BRT TransJakarta waktu ke-						
	Y_t	Y_{t-1}	Y_{t-2}	Y_{t-3}	Y_{t-7}	Y_{t-14}	Y_{t-21}
22-01-2023	209790	225.222	341.682	347.724	206.039	207.692	184.616
23-01-2023	215476	209790	225222	341682	349577	352.644	314.296
24-01-2023	354516	215476	209790	225222	352836	356.003	339.823
25-01-2023	352487	354516	215476	209790	353749	357703	348919

Tanggal	Residual Model SARIMAX						
	ε_t	ε_{t-1}	ε_{t-2}	ε_{t-3}	ε_{t-7}	ε_{t-14}	ε_{t-21}
22-01-2023	7049,79	-635,52	106,98	483,31	-1861,9	-99,56	16,08
23-01-2023	-920,30	7049,79	-635,52	106,98	2878,28	6037,09	7,08
24-01-2023	1,53	-920,30	7049,79	-635,52	911,50	1629,94	6,12
25-01-2023	-483,87	1,53	-920,30	7049,79	752,26	1257,10	5,11

Kombinasi lag optimal ditentukan pada tahap optimasi.

2 ROLLING STATISTICS DAN CYCLIC ENCODING

Hari dalam sepekan	Sin(dow)	Cos(dow)
Minggu	$-2{,}449294e^{-16}$	1,00000
Senin	0,7818315	0,623490
Selasa	0,9749279	-0,222521
Rabu	0,4338837	-0,900969
Kamis	-0,4338837	-0,900969
Jumat	-0,9749279	-0,222521
Sabtu	-0,7818315	0,623490

Untuk mempertahankan sifat siklis hari dalam satu pekan

Tanggal	Pengguna	Rolling mean 7	Rolling std 7
22-01-2023	209790	310975,571429	65486,159802
23-01-2023	215476	311511,428571	64492,181174
24-01-2023	354516	292354,142857	70899,286829
25-01-2023	352487	292594,142857	71140,578525

Tanggal	Residual	Rolling mean 7	Rolling std 7
22-01-2023	7049,778161	376,411555	1460,886056
23-01-2023	-920,296753	1649,512853	2613,530972
24-01-2023	1,533402	1106,859193	2708,505412
25-01-2023	-483,873389	976,864388	2741,085478

Rolling statistic merepresentasikan rata-rata dan variasi data selama 7 hari terakhir

LIGHTGBM

OPTIMASI HYPERPARAMETER

Optuna 75 trial → Evaluasi TSCV (Expanding Window) 4-Fold → Pilih kombinasi dengan rata-rata MAE terendah → Refit dan peramalan

Konfigurasi TSCV

Parameter	Nilai
Jumlah fold	4
Horizon prediksi per fold	61
Ukuran data latih awal	638
fixed_train_size	False
refit	True

Parameter	Ruang Pencarian	Nilai Optimal
n_estimators	[100,500]	**472**
max_depth	[3,7]	**7**
min_data_in_leaf	[20,50]	**21**
learning_rate	[0.01 0.1]	**0,0894**
num_leaves	[2,50]	**38**
reg_alpha	[0,1]	**0,9**
reg_lambda	[0,1]	**0,3**
Lag	[1,2,3,7,14,21], [1,2,7,14,21], [1,7,14,21], [1,2,3,7], [1,2,3,7,14], [1,2,7,14], [1,7,14], [1,2,7], [1,7], [1,2,3], [1,2]	**1, 7, 14, 21**

HYBRID SARIMAX-LIGHTGBM

OPTIMASI HYPERPARAMETER

Variabel target : Residual SARIMAX

Optuna 75 trial → **Evaluasi TSCV (Expanding Window)** → **Pilih kombinasi dengan rata-rata MAE terendah** → **Refit dan peramalan**

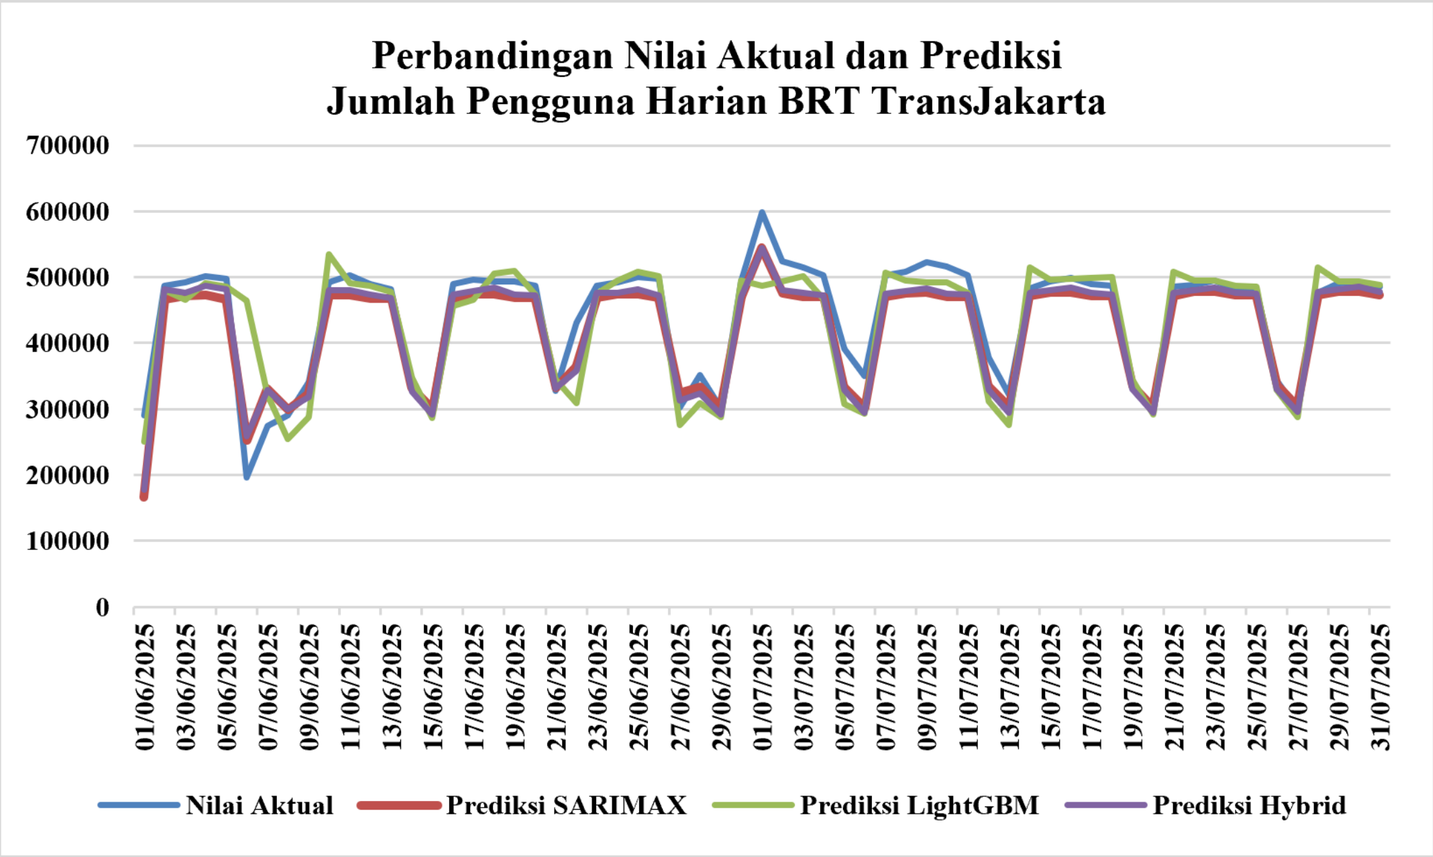
Konfigurasi TSCV

Parameter	Nilai
Jumlah fold	4
Horizon prediksi per fold	61
Ukuran data latih awal	638
fixed_train_size	False
refit	True

Parameter	Ruang Pencarian	Nilai Optimal
n_estimators	[100,500]	**153**
max_depth	[3,7]	**5**
min_data_in_leaf	[20,50]	**30**
learning_rate	[0.01 0.1]	**0,0385**
num_leaves	[2,50]	**14**
reg_alpha	[0,1]	**0,4**
reg_lambda	[0,1]	**0,6**
Lag	[1,2,3,7,14,21], [1,2,7,14,21], [1,7,14,21], [1,2,3,7], [1,2,3,7,14], [1,2,7,14], [1,7,14], [1,2,7], [1,7], [1,2,3], [1,2]	**1, 2 , 3**

HASIL PERAMALAN

Prodi Matematika
Fakultas Sains dan Teknologi
UIN Syarif Hidayatullah Jakarta



Berdasarkan hasil prediksi ketiga model mampu mengikuti pola nilai aktual dengan cukup baik Meskipun demikian, pada beberapa tanggal masih terlihat perbedaan yang cukup besar antara nilai aktual dan hasil prediksi. Sedangkan prediksi model LightGBM menghasilkan kesalahan yang cukup sering dibandingkan dengan kedua model lainnya.

HASIL EVALUASI TERBARU

Prodi Matematika
Fakultas Sains dan Teknologi
UIN Syarif Hidayatullah Jakarta

Metrik Evaluasi	Hasil Evaluasi Model		
	SARIMAX	LightGBM	Hybrid SARIMAX-LightGBM
RMSE	32.161,33	48.278,42	**30.489,99**
MAE	24.918,89	27.439,20	**22.364,07**
MAPE	6,1053%	7,8895%	**5,6688%**

Model dengan nilai akurasi terbaik ➡ **Hybrid SARIMAX-LightGBM**

KESIMPULAN

Hasil prediksi dari ketiga model dapat mengikuti pola musiman mingguan dari data dengan cukup baik

SARIMAX menghasilkan prediksi yang baik terutama pada Idul Adha dan beberapa hari di akhir pekan, meski residual tidak berdistribusi normal.

LightGBM kurang stabil pada nilai ekstrem (Idul Adha 6 Juni 2025, promo tarif 1 Juli 2025) dimana model menghasilkan error prediksi cukup besar.

Prediksi model hybrid memberikaan hasil prediksi yang baik pada 1 Juli 2025 dan saat hari kerja, secara umum prediksi model lebih sering mendekati nilai aktual dibandingkan dengan kedua model lainnya.

Model hybrid adalah model terbaik berdasarkan metrik evaluasi MAE, MAPE, dan RMSE yang menunjukkan bahwa pendekatan hybrid mampu meningkatkan akurasi prediksi dibandingkan penggunaan model SARIMAX maupun LightGBM secara individual pada data jumlah pengguna harian BRT TransJakarta.

SARAN

1. Menambah periode data
2. Perluas kandidat lag features
3. Menambah variabel eksogen (cuaca, ekonomi)
4. Mengeksplorasi model ML/DL lain
5. Mocoba Teknik optimasi hyperparameter yang lain
6. Mempertimbangkan penggunaan SARIMAX dengan asumsi distribusi lainnya
7. Mengembangkan model prediksi pada tingkat rute/halte.

TERIMA KASIH